GEMQ 论文阅读笔记

论文： Jianing Deng et al., GEMQ: Global Expert-Level Mixed-Precision Quantization for MoE LLMs.

论文主页： https://proceedings.mlr.press/v306/deng26t.html

论文 PDF： https://proceedings.mlr.press/v306/deng26t/deng26t.pdf

官方代码： https://github.com/jndeng/GEMQ

一、研究背景与问题

混合专家模型（Mixture-of-Experts，MoE）通过路由机制选择部分专家参与计算，但模型仍需要存储大量专家参数，因此存在显存占用较高的问题。混合位宽量化允许不同专家使用不同精度的权重表示，从而在压缩模型的同时尽可能保留模型性能。

已有专家混合位宽方法通常在每一层内部独立分配位宽，没有充分考虑不同层之间的专家重要性差异。此外，专家权重量化后，其输出会发生变化，进而影响路由器（Router）的专家选择，造成额外的精度损失。

论文要解决的问题： 如何从整个 MoE 模型的角度合理分配专家位宽，并通过调整路由器和改进量化流程，降低极低位宽量化带来的性能损失。

二、论文的核心观察

2.1 不同层和不同专家的重要性存在差异

不同层中的专家对模型输出的影响并不相同，即使处于同一层，不同专家对量化误差的敏感程度也可能存在差异。如果每一层采用独立的位宽预算，可能无法将有限的精度资源分配给真正重要的专家。

2.2 专家量化会影响路由器的选择

路由器根据专家得分选择 Top-K 个专家。专家权重量化后，专家输出发生变化，可能导致路由器选择与原始模型不同的专家。论文在 Mixtral-8×7B 的 1.5 bit 量化实验中发现，超过 40% 的 Token 被分配到了与原始模型不同的专家。

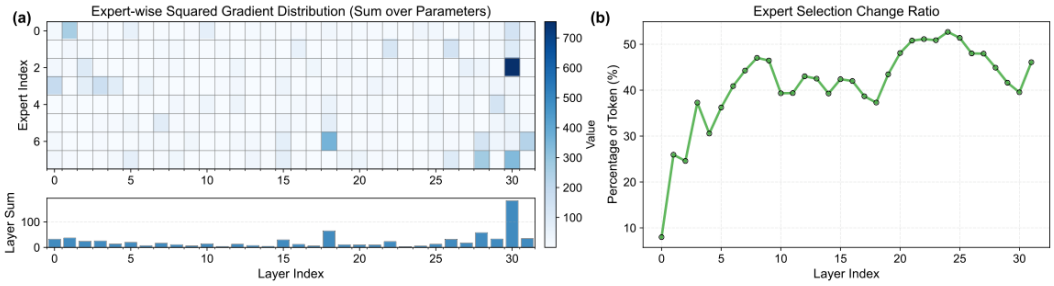


图 1 专家重要性与量化前后的路由变化

图 1(a) 展示不同层和不同专家的权重敏感度存在差异；图 1(b) 展示量化前后专家选择的变化情况。这说明专家位宽分配需要考虑全局重要性，同时还应关注量化对路由行为的影响。

三、GEMQ 的方法思路

GEMQ 是一种面向 MoE 模型的全局专家级混合精度量化方法，主要包含三个部分。

3.1 全局专家位宽分配

GEMQ 将整个模型中的专家放在统一预算下进行比较，而不是逐层独立分配位宽。作者利用校准数据估计不同专家在不同位宽下造成的任务损失，并采用线性规划（Linear Programming，LP）优化位宽配置，使模型在满足总位宽预算的情况下尽可能减少精度损失。

与单纯依据专家激活频率分配位宽不同，该方法重点估计量化某个专家后对模型任务损失的影响。

3.2 全局路由器微调

专家量化后，原有路由器的选择策略可能不再适合量化后的模型。GEMQ 使用少量校准数据微调路由器权重，使其适应量化后的专家输出。由于路由器参数占模型总参数的比例很小，因此不需要重新训练整个大模型。

3.3 渐进式量化

在极低位宽下，直接根据原始模型估计专家重要性可能不够准确。GEMQ 采用逐步降低位宽的方式：先在较高位宽下量化模型，再微调路由器，随后根据当前模型重新估计专家重要性，进一步降低位宽，直到达到目标预算。

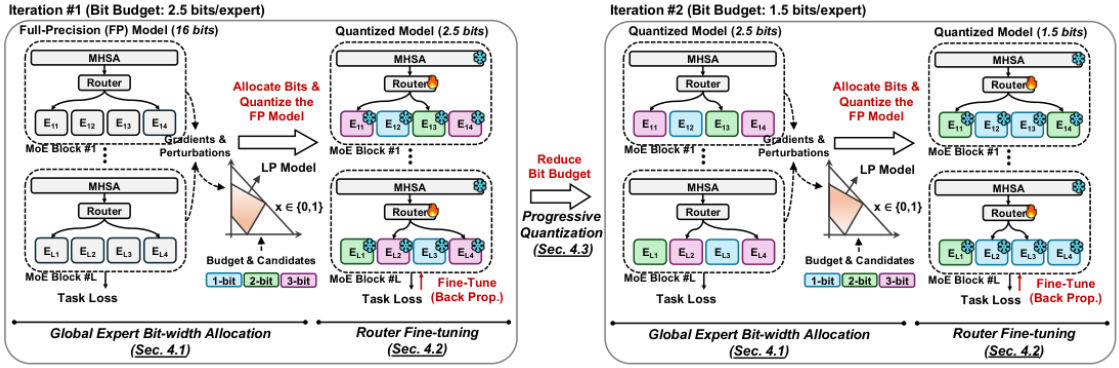


图 2 GEMQ 整体框架

图 2 展示了全局位宽分配、专家量化和路由器微调的循环过程。每轮量化后，模型都会更新专家重要性估计，再进行下一轮更低位宽的量化。

四、方法流程总结

GEMQ 的整体流程可以概括为五步：

1. 收集统计信息： 使用校准数据分析不同专家在不同位宽下的量化损失。
2. 全局分配位宽： 通过线性规划，在总位宽预算下优化专家位宽配置。
3. 执行专家量化： 使用 GPTQ 对专家权重进行后训练量化（PTQ）。
4. 微调路由器： 调整 Router 参数，使其适应量化后的专家。
5. 渐进式优化： 重新评估专家重要性，逐步降低位宽，直至达到目标压缩水平。

五、实验结果与评价指标

论文在 DeepSeek-V2-Lite、Qwen1.5-MoE、Qwen3-30B-A3B 和 Mixtral-8×7B 四种 MoE 模型上开展实验，并与统一位宽量化（Uniform）、已有专家混合位宽方法（PMQ）等方案进行比较。

论文报告的主要结果如下：

1. 在 Mixtral-8×7B 的 2.0 bit 设置下，GEMQ 的七项零样本任务平均准确率达到 64.03，高于 Uniform 的 63.78 和 PMQ 的 61.70。
2. 在 1.5 bit 极低位宽设置下，GEMQ 的平均准确率为 52.00，略高于 PMQ 的 51.78，明显高于 Uniform 的 47.45。
3. 在 DeepSeek-V2-Lite 的 1.5 bit 设置下，相比 FP16 基线，推理峰值显存从 31.6 GB 降至 5.2 GB，解码速度从 159.4 tokens/s 提升至 2

48.4 tokens/s。

这些结果表明，全局专家位宽分配和路由器微调能够改善低位宽量化后的模型表现，同时降低推理资源开销。但实验结果对应特定模型和硬件条件，不能直接推广到所有 MoE 模型。

5.1 消融实验

论文通过消融实验分别测试全局位宽分配、路由器微调和渐进式量化的作用。结果表明，加入路由器微调和渐进式量化后，多数测试设置下模型表现得到改善，尤其在低位宽场景下作用更加明显。

5.2 量化开销

GEMQ 的全局重要性估计和路由器微调会增加离线量化阶段的时间与显存开销。以 Mixtral-8×7B 的单阶段 2-bit 量化为例，GEMQ 总耗时为 2310.2 秒，PMQ 为 2162.0 秒。因此，GEMQ 在提高量化效果的同时，也引入了额外的计算成本。

六、论文的主要贡献与局限

主要贡献：

1. 提出全局专家级位宽分配方法，使不同层和不同专家能够在统一预算下进行比较，避免逐层独立分配造成的局部最优。
2. 引入路由器微调，缓解专家量化后路由行为变化带来的精度损失。
3. 提出渐进式量化策略，通过逐步更新专家重要性估计，改善极低位宽下的量化效果。
4. 在多种 MoE 模型上进行实验，并通过真实 GPU 推理测试验证模型压缩与推理性能之间的关系。

主要局限：

1. 依赖校准数据： 校准数据的领域分布会影响量化效果，针对数学等特定任务可能需要使用领域匹配的数据。
2. 离线开销较高： 梯度计算、重要性估计和路由器微调会增加量化阶段的时间与显存需求。
3. 极低位宽仍存在精度损失： 即使采用全局位宽分配和渐进式量化，也无法完全避免低位宽造成的模型性能下降。

七、对“MoE LLM 的专家混合位宽压缩方案探索”的启发

MxMoE 主要研究模块级混合位宽分配及 GPU 执行效率优化，而 GEMQ 进一步研究了跨层专家位宽分配和量化后的路由器适应问题。两篇论文从不同角度说明，MoE 模型的混合位宽压缩不能只考虑参数存储，还需要关注专家重要性和量化后的模型行为。

对于本课题，可以从以下方向进行探索：

1. 专家重要性评估： 结合专家激活频率、量化敏感度和任务损失变化，分析不同特征对位宽分配的影响。
2. 全局位宽分配： 在相近平均位宽下，对比逐层分配和全局分配策略，验证全局优化是否具有优势。
3. 路由变化分析： 统计量化前后专家选择的变化情况，比较加入路由器微调前后的模型性能。
4. 渐进式量化： 对比一次性量化和逐步降低位宽两种方式，分析渐进式策略是否能够改善低 bit 下的精度。