MxMoE 论文阅读笔记

论文：Haojie Duanmu et al., MxMoE: Mixed-precision Quantization for MoE with Accuracy and Performance Co-Design, ICML 2025, PMLR 267, pp. 14793–14806.

论文主页：https://proceedings.mlr.press/v267/duanmu25a.html

论文 PDF：
https://raw.githubusercontent.com/mlresearch/v267/main/assets/duanmu25a/duanmu25a.pdf

官方代码：https://github.com/cat538/MxMoE

一、研究背景与问题

混合专家模型（Mixture-of-Experts，MoE）通过路由机制，把不同输入 Token 分配给部分专家计算。它能够在不让每个 Token 都经过全部专家的情况下扩展模型容量，但模型仍然包含大量专家参数，因此部署时仍面临参数存储、显存占用和推理效率方面的压力。

量化是降低模型参数表示位宽的一种常见方法。例如，将权重从较高位宽改为较低位宽表示，可以减少权重的存储需求。不过，统一量化存在两个问题：第一，不同线性模块对量化的敏感程度不同；第二，不同专家被激活的频率不同，其计算负载和硬件执行特征也可能不同。因此，只给整个模型统一设置位宽，不一定能同时获得较好的模型精度和推理速度。

论文要解决的问题：如何根据模块的量化敏感度、专家激活情况以及硬件执行特征，合理分配不同位宽，并让混合位宽配置在 GPU 上高效执行。

二、论文的核心观察

2.1 不同线性模块的量化敏感度不同

MoE 专家通常包含多个线性变换模块，例如 Gate、Up 和 Down 投影。不同模块在降低位宽后，造成的量化损失可能存在明显差异。若所有模块统一使用低位宽，部分敏感模块可能出现较大的精度损失；若全部使用高位宽，则压缩效果可能不够理想。

2.2 不同专家的激活频率存在差异

路由机制会将 Token 分配给不同专家，各专家接收到的 Token 数量可能不同。激活频率差异会影响专家的计算负载，也可能让不同专家呈现不同的硬件性能特征。因此，位宽分配除了考虑精度，还需要考虑实际计算性能。

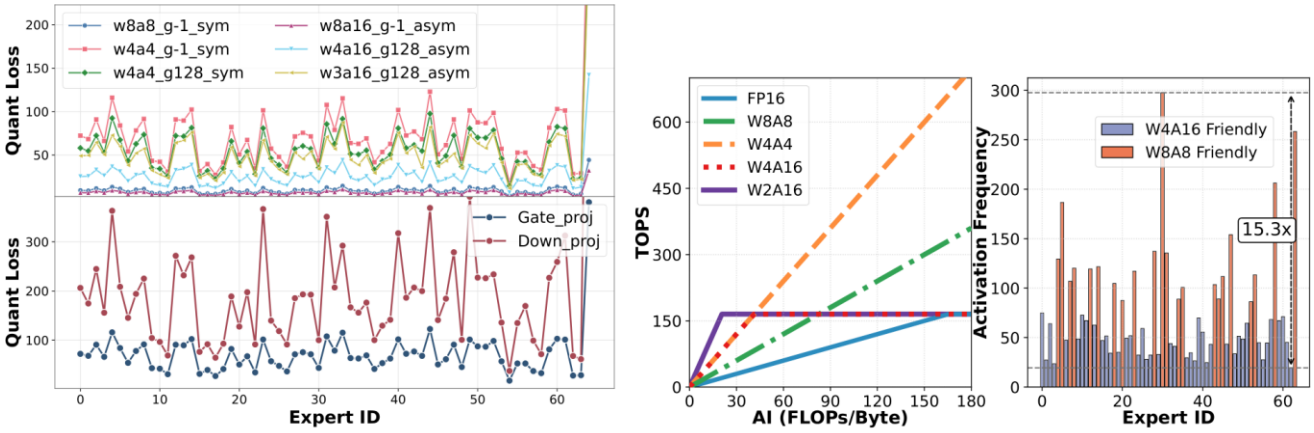


图 1 不同专家/线性模块的量化损失、硬件性能特征及专家激活分布

图 1 展示了不同专家/线性模块在不同量化设置下的量化损失，以及低位宽计算的硬件性能特征和专家激活分布。它支持论文的出发点：模块之间并不完全相同，统一位宽可能无法充分利用各模块的特点。

三、MxMoE 的方法思路

MxMoE 是一个同时考虑模型精度和系统执行效率的混合精度量化框架。其总体流程可以概括为以下几个阶段。

3.1 收集离线统计信息

首先收集与量化和运行性能有关的信息，包括不同模块的量化损失、专家激活模式，以及不同量化配置在目标硬件上的性能表现。这些信息为后续的位宽选择提供依据。

3.2 评估候选量化配置

对不同模块和不同量化位宽的候选配置，评估其可能造成的精度损失，并结合硬件性能分析，估计不同配置的执行效率。这里的关键不是只是考虑低位宽能省多少空间，而是同时考虑会损失多少精度和实际运行是否高效。

3.3 优化混合位宽分配

作者使用整数线性规划（Integer Linear Programming，ILP）来搜索符合约束的位宽配置。可以把 ILP 理解为一种在多个候选方案中，根据目标和约束寻找较优组合的优化方法。它不是简单地给每个专家随意指定一个位宽，而是将量化损失和性能因素纳入配置选择。

3.4 生成混合精度 GPU 计算内核

确定位宽配置后，MxMoE 还会生成适配混合精度配置的 GPU 计算内核。论文使用混合精度 GroupGEMM，使不同精度的矩阵乘法能够以适合该方案的方式执行。

量化降低数据表示位宽，不会自动保证实际推理速度提升。 如果执行实现不高效，数据转换或内核调度等开销可能抵消一部分收益。因此，MxMoE 同时考虑算法层面的位宽分配和系统层面的执行效率。

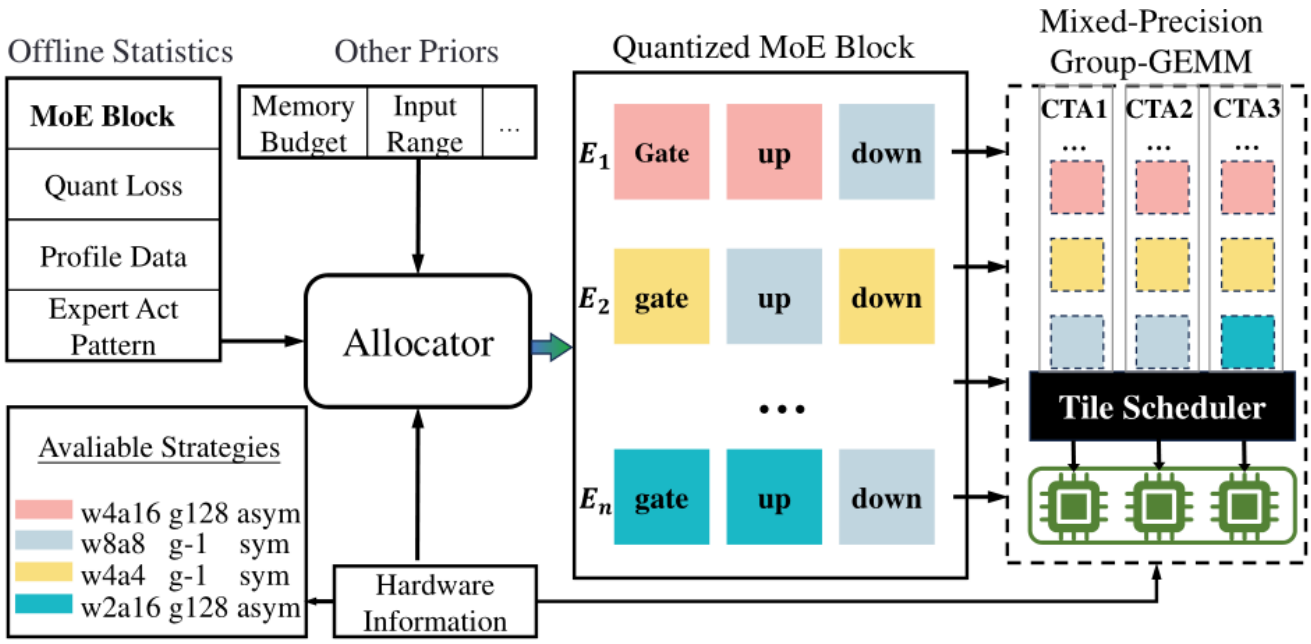


图 2 MxMoE 混合精度 Group-GEMM 示意图

图 2 左侧表示 MoE 专家中不同的线性模块可以使用不同精度；右侧表示将不同精度的矩阵乘法组织到混合精度 Group-GEMM 执行过程中，并通过调度机制协调计算。

四、方法流程总结

可以将 MxMoE 的方法整理成五步：

1. 分析模型：收集模块量化损失、专家激活和硬件性能等信息。
2. 建立候选方案：考虑不同模块可选的量化位宽及其精度影响。
3. 优化配置：结合量化损失和性能约束，求解混合位宽分配方案。
4. 生成执行内核：为混合精度配置生成相应的 GPU 计算实现。
5. 实验验证：评估量化后的语言建模表现和实际推理性能。

五、实验结果与评价指标

论文在多种 MoE 模型和量化配置上开展评估，并与已有量化方法和统一位宽方案进行比较。论文摘要报告了以下结果：

1. 在特定的 2.25-bit 设置下，WikiText-2 困惑度（Perplexity，PPL）比 GPTQ 低 2.4。

2. 相比全精度模型，最高实现 3.4 倍加速。
3. 在特定的 5-bit 权重与激活量化设置下，相比精度相当的统一量化方案，最高实现 29.4% 加速。

这些结果对应论文中的特定模型、配置和实验条件，不是所有 MoE 模型都能达到相同收益。

5.1 困惑度（PPL）是什么？

困惑度是语言建模任务常用的评价指标之一，通常越低越好。论文中困惑度降低 2.4 不是准确率提高 2.4%，两者不是同一概念。

5.2 加速比是什么？

加速比通常按“基线方案耗时 ÷ 新方案耗时”计算。3.4 倍加速意味着在对应测试条件下，新方案的运行速度约为基线的 3.4 倍。它是特定实验条件下的结果，不代表所有任务都会有相同加速。

5.3 为什么要与统一位宽量化比较？

混合位宽的目标之一，是在相近的精度或位宽预算下，比统一位宽方案取得更好的整体效果。因此，公平比较时应关注模型结构、硬件、输入长度、批次大小、平均位宽和精度等条件是否可比。

六、论文的主要贡献

1. 从实验分析出发，指出 MoE 内不同线性模块的量化敏感度存在差异。
2. 指出专家激活频率差异会导致计算特征不同，位宽分配需要考虑硬件执行效率。
3. 提出结合量化损失、专家激活特征和硬件性能的混合精度优化框架。
4. 通过生成混合精度 GroupGEMM 内核，将位宽配置与实际 GPU 执行结合起来。
5. 在论文报告的实验设置下，相较于若干基线方法取得精度或推理性能收益。

七、对“MoE LLM 的专家混合位宽压缩方案探索”的启发

本课题计划分析专家激活频率、路由频率、参数分布、任务重要性和量化敏感度，并尝试为不同专家分配不同位宽。MxMoE 为课题提供了直接参考，但也提示我们需要明确研究差异：MxMoE 已经做到了线性模块级混合位宽和性能协同优化，因此不能仅把给不同专家设置不同位宽直接当作充分的创新点。

后续可以从以下问题逐步探索：

1. 专家级分配是否有实际优势？在相近平均位宽下，与统一位宽及模块级方案比较精度和资源开销。
2. 哪些统计特征真正有用？分别测试激活频率、量化敏感度、参数分布等信息，观察它们对位宽选择的贡献。
3. 能否兼顾精度与推理速度？除模型精度外，还应测量实际推理延迟、吞吐量和显存占用。
4. 是否需要专门内核？初期可以先使用现有量化工具验证分配策略；只有在确认策略有效且性能成为瓶颈后，再考虑专门的内核优化。

建议的初始对比方案包括：原始模型、统一位宽量化、随机混合位宽、基于量化敏感度的混合位宽，以及结合专家特征的混合位宽。所有方案尽可能在相近的平均位宽和一致的测试条件下比较。